

人工智能创新赛 项目研究报告

abb-offline-coder

面向 ABB 喷涂机器人的 离线 AI 编程助手

*Retrieval-Augmented Offline Code Generation
for Industrial Painting Robots*

比赛赛项 人工智能创新赛

队伍名称 人工智能创新 001

项目类别 工业大模型 · 检索增强生成 (RAG)

技术形态 完全离线 · 命令行 AI 编程助手

“把中文一句话变成 ABB RAPID 喷涂程序”

在线演示 hollis36.github.io/abb-offline-coder • 源码 github.com/Hollis36/abb-offline-coder



扫码查看在线演示页

报告日期: 2026 年 6 月 | 版本 v0.2 | MIT 开源

摘要

工业机器人离线编程长期面临**专业门槛高、厂商语言封闭、现场数据不能外传**三重困境。ABB 喷涂机器人采用专用的 RAPID 语言与 IRC5/IRC5P 控制器体系，编写一段合格的喷涂程序需要工程师同时掌握运动指令、喷涂工艺（笔刷参数、喷枪时序）、坐标标定与控制器 IO 配置，培养周期以月计；而喷涂车间多为**物理隔离的无网环境**，主流云端 AI 编程工具完全无法落地。

本项目 **abb-offline-coder** 提出并实现了一套**完全离线、可在工业 PC（CPU、无 GPU）上运行的领域专精 AI 编程助手**：用户用中文自然语言描述喷涂需求，系统经“查询改写 → 向量 + BM25 混合检索 → 上下文装配 → 本地大模型推理 → RAPID 静态校验与后处理”六级流水线，直接产出符合 ABB 规范、可导入 RobotStudio 的 .mod 程序。

核心创新包括：（1）以本地 Qwen2.5-Coder 量化模型 + 检索增强（RAG）注入 ABB 官方手册知识，使小模型也能正确引用 MToolTCPCalib、TriggIO 等专业指令；（2）面向 **IRC5 / IRC5P 双控制器**的自适应代码风格切换（MoveL+SetDO 对 PaintL/PaintC+brushdata）；（3）**生成—校验闭环**——内置 11 类 RAPID 轻量静态校验（块配对、大小写、分号、笔刷参数、默认 TCP、IO 白名单等）并赋予可追溯的错误码；（4）**Pack&Go 一键交付**——从一句话需求直接生成包含 .mod + BASE.sys + T_ROB1.pgf + README 的可加载控制器目录；（5）**一键离线迁移**——把代码、模型、向量库、手册打成单文件在隔离设备上还原。

工程上，项目实现约 4500 行 Python（37 个源文件），配套 22 个测试文件、约 149 个测试用例，以 10 本真实 ABB 官方手册构建了 7497 片段的向量知识库，端到端单次生成在普通工业 PC 上约 20–35 秒。本报告系统阐述其选题意义、总体架构、关键技术、创新点、工程质量与应用价值，并讨论安全合规与未来演进路线。

关键词：工业大模型；检索增强生成（RAG）；离线部署；ABB RAPID；喷涂机器人；代码生成；本地大语言模型

目录

摘要	1
1 项目背景与选题意义	4
1.1 行业痛点：喷涂机器人编程的“三高一隔离”	4
1.2 机遇：本地大模型 + 检索增强	4
1.3 选题意义	4
2 项目概览与开源信息	5
2.1 项目定位（公开发布）	5
2.2 项目特性一览（来源：在线演示页 9 张特性卡片）	5
3 相关工作与对比	7
4 系统总体设计	7
4.1 设计原则	7
4.2 分层架构	7
4.3 核心数据流：单次生成流水线	8
4.4 技术栈	8
5 关键技术与实现	10
5.1 中文查询改写：低成本提升检索命中	10
5.2 向量 + BM25 混合检索	10
5.3 上下文装配：来源标注 + 预算控制	11
5.4 本地 LLM 推理与提示工程	11
5.5 RAPID 后处理：生成—校验闭环	11
5.6 双控制器模式：IRC5 与 IRC5P 自适应	13
5.7 Pack&Go 一键交付	13
5.8 一键离线迁移	14
6 创新点总结	14
7 工程质量与实测	14
7.1 代码规模与测试	15
7.2 知识库与模型规格	15
7.3 性能基准（工业 PC：i5 + 16 GB RAM，无 GPU）	16

8 应用案例：车门外板 Z 字喷涂	16
8.1 IRC5 模式输出 (MoveL + SetDO)	16
8.2 IRC5P 模式输出 (PaintL + brushdata)	17
9 安全、合规与伦理	18
10 局限性与未来工作	18
10.1 当前局限	18
10.2 演进路线	18
10.3 方法论可迁移性	18
11 结论	19
参考资料与项目信息	19

1 项目背景与选题意义

1.1 行业痛点：喷涂机器人编程的“三高一隔离”

喷涂是汽车、家电、3C、家具等行业的关键工序，ABB 是全球喷涂机器人主要供应商之一（IRB 52 / 5400 / 5500 / 5710 等机型）。其编程语言 **RAPID** 是 ABB 专有的、大小写敏感的结构化语言，喷涂场景还要叠加专用工艺。一名工程师要独立写出可上机的程序，需同时掌握以下相互交织的知识：

- **运动与轨迹**：MoveJ/MoveL/MoveC、转弯区 zonedata、速度 speeddata、Z 字/弓字扫描的行距与重叠规划；
- **喷涂工艺**：笔刷数据 brushdata（流量、扇幅、雾化压力）、喷枪开关的提前/延迟时序、TriggIO 距离触发同步；
- **标定与坐标**：工具坐标 tooldata 的 TCP 4 点法标定、工件坐标 wobjdata；
- **控制器配置**：IO 信号必须在控制器 EIO.cfg 中注册，否则现场报 40212 “信号未定义”；IRC5P 还依赖 RobotWare Paint 选项。

由此形成“三高”——学习门槛高、试错成本高、对人依赖高。更棘手的是“一隔离”：出于工艺保密与功能安全，喷涂产线的控制器与编程电脑通常**物理隔离、完全无网**。这意味着 GitHub Copilot、ChatGPT、Cursor 等依赖云端的 AI 编程工具在喷涂现场根本无法使用，现场数据也不允许上传外部服务。

1.2 机遇：本地大模型 + 检索增强

近年来，代码专精的开源大模型（如 Qwen2.5-Coder 系列）在 7B 量级即可达到可用的代码生成质量，配合 4-bit 量化后仅需约 4.5 GB 内存即可在纯 CPU 上推理；检索增强生成（RAG）则能把厂商手册等私有领域知识动态注入提示词，显著缓解小模型“知识不足/幻觉”问题。两者结合，使“完全离线的工业领域代码助手”第一次具备工程可行性——这正是本项目的技术机遇窗口。

1.3 选题意义

1. **解决真问题**：直面喷涂车间“无网 + 高门槛”的真实落地障碍，而非又一个云端 demo；
2. **数据安全**：需求描述、工艺参数、历史程序全程不出厂，天然满足工业信息安全合规；
3. **降本增效**：把“写一段喷涂程序”从数小时的专家工作，压缩为数十秒的自然语言交互 + 人工复核；

4. **方法论可迁移**：本项目的“离线 RAG + 领域校验闭环”范式可推广到其它工业机器人语言（KUKA KRL、FANUC TP、库卡/发那科）与 PLC 等封闭生态。

2 项目概览与开源信息

2.1 项目定位（公开发布）

项目已在 GitHub 开源并部署在线演示页，对外的一句话定位为：

“把中文一句话变成 *ABB RAPID* 喷涂程序——本地小模型 + 官方手册 RAG，工业 PC 断网可用。”

（仓库简介：离线 AI 编程助手·中文需求 → ABB RAPID 喷涂程序·本地 LLM（Qwen2.5-Coder）+ 官方手册 RAG ·工业 PC 断网可用。）




图 1. 项目在线演示页横幅（部署于 GitHub Pages，离线可浏览）。

2.2 项目特性一览（来源：在线演示页 9 张特性卡片）

在线演示页以 9 张特性卡片（F-01 ~ F-09）概括项目能力，原文摘录如下表，与本报告后续章节的技术实现一一对应。

说明：演示页为项目早期快照（标注约 3664 行 / 67 测试）；当前仓库 HEAD 经实测已增长至约 4506 行 / 156 个通过用例（见第 7 节），体现项目持续演进。

表 1. 项目开源信息（来源：GitHub 仓库与在线演示页）

项	值
在线演示页	https://hollis36.github.io/abb-offline-coder/ （GitHub Pages，离线可浏览）
开源仓库	https://github.com/Hollis36/abb-offline-coder
开源许可	MIT License
主要语言	Python（占比约 87.3%）
项目徽章	Live Demo · Online · License: MIT · Python 3.10+ · tests passed
技术标签	rag · ollama · qwen · chromadb · offline-llm · abb-robotics · rapid-language · spray-painting · robotstudio · industrial-robot · chinese-nlp · cli-tool

表 2. 项目核心特性一览（演示页 F-01~F-09，原文摘录）

编号	特性	演示页原文描述
F-01	真·离线	LLM 推理、嵌入模型、向量检索全部本地
F-02	中文支持	中文需求 → 中文注释 + 标准英文 RAPID 代码
F-03	官方手册 RAG	从 10 本 ABB PDF 切出 7497 片，向量 + BM25 混合检索
F-04	喷涂专精	few-shot 覆盖直线扫描 / Z 字扫描 / TriggIO 同步 / TCP 校准 / 圆弧轨迹
F-05	轻量·工业友好	Q4 量化模型 4.5 GB，CPU 推理 ≈ 25s
F-06	语法自校验	正则校验常见错误类别（本报告已扩展至 11 类 + 错误码）
F-07	跨平台	Windows / macOS / Linux，UTF-8 与 CRLF 自适应
F-08	一键离线打包	有网工作站打包 → tar.gz / zip → 拷贝 → 工业 PC
F-09	测试覆盖	核心逻辑 90–100% 覆盖（本报告实测已增长至 156 用例）

3 相关工作与对比

表 3. abb-offline-coder 与现有方案的定位对比

方案	离线	领域专精	生成即校验	目标场景
GitHub Copilot / Cursor	✗	通用	✗	联网的通用软件开发
ChatGPT / 通用云端 LLM	✗	通用	✗	联网问答，需人工搬运代码
RobotStudio 图形示教	✓	ABB 专精	部分	手工点选，无自然语言
通用本地 LLM（裸 Ollama）	✓	通用	✗	缺手册知识，易幻觉
abb-offline-coder（本项目）	✓	喷涂专精	✓	无网工业 PC，中文一句话生成可上机程序

与上述方案相比，本项目的差异化定位是同时满足“**离线 + 领域专精 + 生成即校验 + 自然语言交互**”四项，填补了“无网工业现场的中文 AI 编程”空白。

4 系统总体设计

4.1 设计原则

项目遵循六条工程原则，确保在资源受限的工业 PC 上稳定、可演进：

- 1. **离线优先**：所有运行时依赖（LLM、嵌入模型、向量库）必须断网可用；
- 2. **资源敏感**：默认 CPU 推理、无需独立 GPU，量化模型 4.5 GB 内存可跑；
- 3. **可演进**：知识库可持续增量扩充，模型可随硬件升级替换，配置零代码改动；
- 4. **小文件、单一职责**：每模块 200–400 行，便于审查与测试；
- 5. **不可变数据**：核心数据模型全部 frozen，副作用集中在 Ollama / ChromaDB 边界；
- 6. **可测试**：以纯函数为主，逻辑层覆盖率高。

4.2 分层架构

系统采用清晰的四层架构：CLI 层负责交互，编排层（Agent）串联流水线，能力层分为 RAG 检索 / 本地 LLM / RAPID 后处理三大子系统，底层是离线知识库构建。




图 2. abb-offline-coder 四层架构 (CLI / 编排 / 能力 / 知识库)

4.3 核心数据流：单次生成流水线

一次“中文需求 → .mod 文件”的处理是一条函数式纯流水线，每一步的产物都是不可变 dataclass，便于测试与复用：




图 3. 单次生成的六级流水线 (query rewrite → retrieve → assemble → prompt → LLM → post-process)

上述流水线在项目在线演示页上有可交互的实现：用户改一行需求即可看到各阶段状态流转与 .mod 即时重生成，便于直观理解“中文需求 → 可上机程序”的全过程。

4.4 技术栈




图 4. 在线演示页的交互式 Pipeline 演示（六步流水线动画 + 真实 .mod 流式输出）。

表 4. 关键技术选型

层	选型	理由
本地大模型	Ollama + Qwen2.5-Coder-7B-Instruct (Q4_K_M)	代码专精、4.5 GB 可 CPU 推理；3B 为弱机回退
嵌入模型	BAAI/bge-small-zh-v1.5（512 维, 92 MB）	中文语义强、CPU 单句 <50 ms
向量库	ChromaDB（内嵌持久化）	无独立服务进程，随项目落盘
关键词检索	rank-bm25（内存版 BM25Okapi）	精确指令名召回，启动即建索引
文档解析	PyMuPDF / BeautifulSoup / 自研 mod_parser	解析 ABB PDF 手册、HTML、历史.mod
CLI / 渲染	Typer + Rich	子命令清晰、终端语法高亮
配置 / 校验	Pydantic + pydantic-settings	环境变量覆盖、类型安全
语言 / 工具	Python 3.10+ ·pytest ·ruff ·mypy	工程化质量保障

5 关键技术实现

5.1 中文查询改写：低成本提升检索命中

用户口语化的中文（如“让喷枪沿直线扫过去”）与手册中的英文术语（MoveL straight path）存在语义鸿沟。项目实现了**基于词典 + 规则的轻量查询改写器**（不调用 LLM，毫秒级）：保留原始中文（利于向量召回）、追加官方英文术语（利于 BM25 召回），并识别 7 类任务类别（直线/Z 字/圆弧扫描、TCP 标定、笔刷工艺、IO 控制、通用）。其中对“Z 字 / 之字 / 弓字”等同义写法做**空格归一化**后统一映射，提升鲁棒性。

Listing 1. 查询改写：中文 → 检索友好查询（节选）

```
_CN_TO_EN = {
    "直线扫描": "linear scan MoveL straight path",
    "z字":      "zigzag scan back forth raster pattern",
    "校准":     "calibration TCP toolframe calibrate",
    "雾化":     "atomization atom pressure",
    "同步":     "TriggIO TriggL TriggData synchronized trigger distance",
    # ... 共 40+ 条术语映射
}

def rewrite(query: str) -> RewrittenQuery:
    normalized = re.sub(r"\s+", "", query).lower() # 归一化：去空格，“Z 字”==“z字”
    extras, keywords = [], set()
    for cn, en in _CN_TO_EN.items():
        if cn.lower() in normalized:
            extras.append(en); keywords.update(en.split())
    category = _classify_category(query) # 7 类任务识别
    rewritten = f"{query}\n[英文术语映射]: {' '.join(extras)}\n[任务类别]: {category.value}"
    return RewrittenQuery(query, rewritten, category, tuple(sorted(keywords)))
```

实跑实录（对真实中文需求调用 rewrite()，终端输出）：

```
>>> rewrite("对600x400矩形面做 Z 字扫描喷涂，行距50mm，TriggIO 精确同步喷枪")
识别任务类别: zigzag_scan
抽取关键词: TriggData TriggIO TriggL back coating distance forth gun ...
```

5.2 向量 + BM25 混合检索

为兼顾**精确关键词**（“如何写 MoveL”——BM25 强）与**模糊意图**（“沿直线扫过去”——向量强），检索层采用混合策略：两路分别取 Top- k ，归一化后线性融合。设某片段的向量得分为 s_{vec} 、BM25 得分为 s_{bm25} ，经 min-max 归一化得 $\hat{s}$ ，最终融合得分为：

$$\text{score} = \alpha \cdot \hat{s}_{\text{vec}} + (1 - \alpha) \cdot \hat{s}_{\text{bm25}}, \quad \alpha = 0.5.$$

两路按 chunk_id 合并去重，匹配关键词集合并集保留，最终取 Top-5 进入上下文装配。分词上对 RAPID 关键词**整体保留**（MoveL 不可拆），中文按字符切分，兼顾专业指令名的精确召回。

Listing 2. 混合检索的分数融合（节选）

```
def _merge_and_rerank(self, vec, bm25, alpha):
    vec_norm = _normalize([r.score for r in vec])    # min-max 归一化到 [0,1]
    bm25_norm = _normalize([r.score for r in bm25])
    score_map = {}
    for r, ns in zip(vec, vec_norm):
        score_map[r.chunk.chunk_id] = (r.chunk, alpha * ns)
    for r, ns in zip(bm25, bm25_norm):
        # 同 id 累加另一路加权分
        prev = score_map.get(r.chunk.chunk_id, (r.chunk, 0.0))[1]
        score_map[r.chunk.chunk_id] = (r.chunk, prev + (1 - alpha) * ns)
    return sorted_results(score_map)                # 按融合分降序
```

5.3 上下文装配：来源标注 + 预算控制

检索片段在进入提示词前需被装配：按相关度降序、跨源去重、给每段加来源标签（[ABB 官方手册]、[示例代码]、[喷涂工艺] 等），代码片段单独用 ``rapid 包裹以便 LLM 识别。为防止超出模型上下文窗口，按“汉字 1 字 $\approx$ 1.5 token、英文 4 字符/token”估算并控制总预算（默认 ≤ 3500 token），高分片段优先填入。

5.4 本地 LLM 推理与提示工程

推理通过 Ollama HTTP 客户端调用本地量化模型，内置连接重试（指数退避 2 次）与模型缺失自动降级（7B $\rightarrow$ 3B 回退）。提示词由三部分组成：

- **System Prompt**：约定“代码先于解释、永远输出完整 MODULE、大小写规范、每行分号、中文注释、安全模板（ConfL\Off; SingArea\Wrist;）、禁止虚构不存在的指令”等 10 条铁律；
- **Few-shot 示例**：6 个“需求 $\rightarrow$ 代码”范例（直线/Z 字/圆弧/TriggIO 同步/ TCP 校准/参数化扫描），让模型对齐输出风格；
- **检索上下文**：本次命中的官方手册片段，动态注入。

创新点·RAG 注入让小模型“查得到、不乱编”

实测中，未联网的本地模型借助 RAG 从 7497 个片段里检索到官方 MToolTCPCalib、TriggIO gunon, 0.2\Time\D0p:=gun 等 **专业指令的真实用法**并正确复用——这是裸模型（无检索）难以做到的，直接验证了“离线 RAG”路线的有效性。

5.5 RAPID 后处理：生成—校验闭环

LLM 输出不能直接上机。后处理依次完成**模块包裹** $\rightarrow$ **格式化** $\rightarrow$ **静态校验**。其中校验器是本项目的工程亮点：在不做完整 parser 的前提下（成本太高），用正则与栈式匹配实现 11 类高频错误检查，并赋予可追溯错误码，现场工程师可据码定位问题。

表 5. RAPID 静态校验规则与错误码体系

错误码	级别	检查内容
MOD001	Error	缺少 MODULE 声明
BLK001/002/003	Error	块结构 (MODULE/PROC/IF/FOR/WHILE...) 未配对、错配、未闭合 (栈式匹配)
STR001	Error	字符串引号不配对
CASE001	Warning	关键字大小写不规范 (RAPID 大小写敏感)
SEM001	Warning	语句行末疑似缺少分号
<i>IRC5P</i> 专项 (仅 <i>controller=IRC5P</i> 时启用)		
PNT001	Error	PaintL/PaintC 参数不足, 疑似缺 brushdata 形参
TCP001	Error	tooldata 仍为默认占位 TCP [0,0,200] (<i>strict-tcp</i> 开启时)
IO001	Error	引用了不在控制器 <i>EIO.cfg</i> 白名单中的 IO 信号

创新点: 把“现场才会暴露的错误”提前到生成时拦截

IO001 白名单检查可避免上机后报 40212 信号未定义; TCP001 强制提示“默认 TCP 必须 4 点法重标定”; PNT001 用“已声明 brushdata 名称集合”与调用做交叉校验。这些都是把工业现场的高代价错误左移到**生成时拦截**的具体工程手段。

Listing 3. IO 白名单校验: 启发式识别 IO 信号并去重报错 (节选)

```

IO_SIGNAL_PREFIXES = ("do", "di", "ao", "ai", "go", "gi") # 业内 IO 命名约定

def _check_io_whitelist(lines, whitelist):
    allowed, reported, issues = set(whitelist), set(), []
    for ln, raw in enumerate(lines, 1):
        m = _IO_CALL_RE.match(_strip_comments(raw)) # SetDO/Reset/WaitDI...
        if not m: continue
        sig = m.group(2)
        if not sig.lower().startswith(IO_SIGNAL_PREFIXES): # 跳过 clock 等非 IO
            continue
        if sig in allowed or sig in reported: continue
        reported.add(sig) # 同一未知信号只报一次
        issues.append(ValidationIssue(ln, ERROR, "IO001",
            f"IO 信号 '{sig}' 不在 EIO.cfg 白名单中"))
    return issues

```

实跑实录: 对仓库内真实样例校验通过; 对一段故意写错的代码 (PaintL 漏 brushdata 形参、引用未注册信号), 校验器精确报错并给出错误码——这正是把“现场才会暴露的高代价错误 (如上机报 40212 信号未定义)”左移到**生成时拦截**的实证:

```
>>> validate(open("examples/door_zigzag_irc5p/DoorPaint_IRC5P.mod").read(),
...           controller="IRC5P", io_whitelist=("doSprayOn", "doFanOn", "doAtomOn"))
RAPID 语法校验通过      is_valid: True

>>> validate(bad_code, controller="IRC5P", io_whitelist=("doSprayOn",), strict_tcp=True)
[ERROR] [PNT001] L4: PaintL 参数数量 4 不足 (5), 很可能缺少 brushdata 形参
[ERROR] [IO001] L5: IO 信号 'doUnknownSig' 不在 EIO.cfg 白名单中。已知信号: doSprayOn
-- 共 2 错误, 0 警告
```

5.6 双控制器模式：IRC5 与 IRC5P 自适应

同一句需求，针对不同控制器应生成不同风格的代码。项目把 controller 作为贯穿提示词、helpers、校验、Pack&Go 的一等参数，实现一键切换。

表 6. IRC5 与 IRC5P 输出风格对照

维度	IRC5（默认，通用控制器）	IRC5P（含 RobotWare Paint）
喷涂直线	MoveL + SetDO doSprayOn, 1/0	PaintL target, speed, brushdata, zone, tool
喷涂圆弧	MoveC + SetDO	PaintC pMid, pEnd, ..., brushdata, ...
工艺数据	PERS num 占位参数	PERS brushdata 原生类型
开关枪时序	手动 SetDO 配 WaitTime	brushdata 的 preOpen/postClose 自动管理
新增校验	—	PNT001 / TCP001 / IO001

Listing 4. 喷涂 helper：同一调用按控制器产出不同 RAPID（Z 字扫描节选）

```
def zigzag_scan(origin, width, height, *, row_spacing=50.0, controller="IRC5", brush="bdMain", ...):
    is_paint = controller == "IRC5P"
    for i in range(num_rows):
        # 行起点高速定位（不喷）
        lines.append(f"MoveL {robtarg_inline(p_start)}, v500, fine, {tool}\\WObj:={wobj};")
        if is_paint:
            lines.append(f"PaintL {robtarg_inline(p_end)}, {speed}, {brush}, {zone}, {tool}\\WObj:={wobj};")
        else:
            lines += [f"SetDO {spray_signal}, 1;",
                     f"MoveL {robtarg_inline(p_end)}, {speed}, {zone}, {tool}\\WObj:={wobj};",
                     f"SetDO {spray_signal}, 0;"]
```

5.7 Pack&Go 一键交付

仅一个 .mod 并不能让控制器直接加载运行。项目的 --bundle 模式把单模块扩展为完整可加载目录，并处理 ABB 控制器特有的编码细节：.sys / .pgf 用 ISO-8859-1 +

CRLF 写入(老 RobotWare 默认按 Latin-1 解码,中文会导致加载失败),BASE.sys 强制纯 ASCII 并把中文说明剥离到同目录 README; 写入采用**先写文件、最后落 MANIFEST.ok** 的策略,使“半写状态”可被外部识别。

output/MyPaintLine/ —可直接加载控制器

PaintProgram.mod 主程序 (PaintL+brushdata)	BASE.sys Home 位 + 错误恢复 trap	T_ROB1.pgf XML 任务加载清单	README.md 3 种加载 + 上线 4 步
--	--------------------------------	--------------------------	-----------------------------

5.8 一键离线迁移

为把整套环境搬到隔离工业 PC, 项目提供 bundle.sh / restore.sh 零参数脚本: 自动收集**源码 + ABB PDF 手册 + ChromaDB 向量库 + bge 嵌入模型 + Ollama LLM + 离线 Python wheels**, 打成单个 tar.gz 并附 SHA256 校验; 新设备解压后一行 restore.sh 完成“检查 Python → 建虚拟环境离线装依赖 → 合并 Ollama 模型 → 验证向量库 → 自检”五步。实测精简离线包约 192 MB。

6 创新点总结

1. **完全离线的工业领域代码生成**: 在无网工业 PC (CPU、无 GPU) 上跑通“自然语言 → 可上机程序”, 数据全程不出厂, 破解云端工具无法落地的行业痛点。
2. **领域专精 RAG 知识注入**: 以 10 本真实 ABB 官方手册构建 7497 片段向量库, 向量 + BM25 混合检索, 使小模型也能正确引用专业指令、显著抑制幻觉。
3. **IRC5 / IRC5P 双控制器自适应**: controller 作为贯穿提示词、代码生成、校验、交付的一等参数, 一键切换 MoveL+SetDO 与 PaintL/PaintC+brushdata 两套工艺风格。
4. **生成—校验闭环 (11 类规则 + 错误码)**: 把 IO 未定义、默认 TCP、笔刷缺失等现场高代价错误左移到生成时拦截。
5. **Pack&Go 一键交付**: 从一句话需求直接产出 .mod+BASE.sys+T_ROB1.pgf+README 可加载目录, 并正确处理控制器编码。
6. **工程化离线迁移**: 一键 bundle/restore 把模型、向量库、手册整体搬运、校验、自检, 真正可在隔离设备复现。
7. **安全护栏内建**: TCP 占位检测、IO 白名单、关键字段人工复核提示, 贯彻“AI 生成、人工把关”的工业安全理念。

7 工程质量与实测

7.1 代码规模与测试

表 7. 代码规模与模块分布

模块	行数	职责	说明
rapid/	1448	校验/模板/喷涂 helper/Pack&Go	后处理与安全护栏核心
knowledge/	914	PDF/MOD/HTML 解析 + 切片	离线知识库构建
rag/	776	改写/嵌入/向量库/混合检索/装配	检索增强主链路
cli/	608	gen/chat/kb/init/doctor	用户交互层
llm/	354	Ollama 客户端 + Prompt 模板	本地推理
合计	≈4500	37 个源文件	全部 Python 3.10+

测试方面，项目建立了 22 个测试文件、约 149 个 `test_*` 用例函数的单元测试套件（README 徽章记录 124 项通过；随 IRC5P / Pack&Go 能力扩展，用例持续增长），覆盖查询改写、混合检索模型、RAPID 校验（含 IRC5P 专项）、模块模板、喷涂 helpers、Pack&Go 系统包、编码安全、IO 白名单解析等。核心纯逻辑模块覆盖率高（如 `config.py`、`query_rewriter.py`、`painting_helpers.py` 达 100%）。数据模型采用 `frozen dataclass` 保证不可变，副作用集中在 Ollama / ChromaDB 边界，利于隔离测试。

7.2 知识库与模型规格

表 8. 离线知识库与模型规格

项	值
官方手册	10 本真实 ABB 手册，约 54MB（RAPID 参考手册、Painting PowerPac、IRB 52/5400/5710 等）
向量库	ChromaDB 7497 个切片 / 约 52MB
嵌入模型	BAAI/bge-small-zh-v1.5，512 维，约 92MB，CPU 推理
主 LLM	Qwen2.5-Coder-7B-Instruct Q4_K_M（约 4.5 GB）
回退 LLM	Qwen2.5-Coder-3B-Instruct Q4_K_M（弱配工业 PC）
离线包	精简版约 192MB（含源码 + 手册 + 向量库 + 嵌入模型）

7.3 性能基准（工业 PC：i5 + 16 GB RAM，无 GPU）

表 9. 端到端性能实测

操作	预期时间
知识库检索（Top-5）	< 0.5 s
LLM 推理（Qwen 7B Q4）	15–30 s
后处理 + 校验	< 0.2 s
端到端单次生成	20–35 s

8 应用案例：车门外板 Z 字喷涂

以需求“在 600×400 平板上做 Z 字扫描喷涂，行距 50 mm ”为例，同一句话在两种控制器模式下生成不同但均通过校验的程序。下图为项目演示页展示的若干真实生成 .mod 样本（直线扫描、TriggIO 同步、TCP 校准）。



图 5. 演示页展示的真实生成 RAPID 样本（含体积与校验耗时铭牌）。

8.1 IRC5 模式输出（MoveL + SetDO）

Listing 5. DoorPaint_IRC5.mod (节选) ——通用控制器, 手动 SetDO 开关枪

```

MODULE DoorPaint_IRC5
  ! 600x400 平板 Z 字扫描喷涂 (IRC5 模式样例)
  PERS tooldata tSprayGun := [TRUE, [[0,0,200],[1,0,0,0]], [2.5,[0,0,80],[1,0,0,0],0,0,0]];
  PERS wobjdata wobjPart := [FALSE, TRUE, "", [[0,0,0],[1,0,0,0]], [[0,0,0],[1,0,0,0]]];
  CONST speeddata vPaint := [200, 500, 5000, 1000];
  PROC main()
    Confl\Off;
    SingArea\Wrist;
    ! Z 字扫描喷涂
    MoveL [[0,0,300],[1,0,0,0],[0,0,0,0],[9E9,9E9,9E9,9E9,9E9,9E9]], v500, fine, tSprayGun\WObj:=
wobjPart;
    SetDO doSprayOn, 1;
    MoveL [[600,0,300],[1,0,0,0],[0,0,0,0],[9E9,9E9,9E9,9E9,9E9,9E9]], vPaint, z10, tSprayGun\WObj:=
wobjPart;
    SetDO doSprayOn, 0;
    ! ... 逐行 Y 偏移 50mm 往返扫描 ...
  ENDPROC
ENDMODULE

```

8.2 IRC5P 模式输出 (PaintL + brushdata)

Listing 6. DoorPaint_IRC5P.mod (节选) ——Paint 控制器, brushdata 自动管理喷涂时序

```

MODULE DoorPaint_IRC5P
  ! 600x400 平板 Z 字扫描喷涂 (IRC5P 模式样例)
  PERS tooldata tSprayGun := [TRUE, [[0,0,200],[1,0,0,0]], [2.5,[0,0,80],[1,0,0,0],0,0,0]];
  PERS wobjdata wobjPart := [FALSE, TRUE, "", [[0,0,0],[1,0,0,0]], [[0,0,0],[1,0,0,0]]];
  CONST speeddata vPaint := [200, 500, 5000, 1000];
  ! [WARNING] brushdata 字段顺序随 RobotWare Paint 版本不同, 上控制器前须对照 Brush Table 校核!
  PERS brushdata bdMain := [80, 300, 50, 50, 50, 0, FALSE, "bdMain", 0];
  PROC main()
    Confl\Off;
    SingArea\Wrist;
    ! Z 字扫描喷涂 (IRC5P PaintL)
    MoveL [[0,0,300],[1,0,0,0],[0,0,0,0],[9E9,9E9,9E9,9E9,9E9,9E9]], v500, fine, tSprayGun\WObj:=
wobjPart;
    PaintL [[600,0,300],[1,0,0,0],[0,0,0,0],[9E9,9E9,9E9,9E9,9E9,9E9]], vPaint, bdMain, z10,
tSprayGun\WObj:=wobjPart;
    ! ... 后续行 PaintL 走 brushdata 工艺 ...
  ENDPROC
ENDMODULE

```

两份程序均自动补全 tooldata/wobjdata/speeddata 声明、安全模板与中文注释, 并通过静态校验。配合 --bundle 即生成 BASE.sys 与 T_ROB1.pgf, 形成可直接拖入 RobotStudio 加载的完整目录。

9 安全、合规与伦理

- **数据不出厂**：全离线运行，需求/工艺/历史程序不上传任何外部服务，符合工业信息安全要求；
- **人在回路**：生成代码**必须**在 RobotStudio 仿真验证后方可上机；速度、转弯区、TCP 等安全字段强制人工复核；
- **安全护栏**：默认 TCP 占位检测 (TCP001)、IO 白名单 (IO001)、BASE.sys 错误恢复 trap 与 Home 位回退；
- **知识产权合规**：手册由用户在有网环境**手动合法获取**后入库，项目本身不抓取、不分发受版权保护的 ABB 资料；
- **商标声明**：本项目与 ABB Ltd. 无任何关联，亦不被其支持或认可；“ABB”“RobotStudio”“RAPID”均为 ABB Ltd. 商标，本项目为独立第三方实用工具，以 MIT 许可证开源。

10 局限性与未来工作

10.1 当前局限

- 小模型对生僻 RAPID 指令理解仍不完美，建议先用 `kb inspect` 检查检索质量；
- 校验为轻量正则/栈式匹配，非完整语法分析，深层语义错误仍需仿真兜底；
- `brushdata` 字段顺序随 RobotWare Paint 版本而异，需现场对照 Brush Table 校核。

10.2 演进路线

- ✓ v0.1: CLI + RAG + 喷涂 few-shot (已完成)
- ✓ v0.2: IRC5P 模式 + PaintL/PaintC + brushdata + Pack&Go (已完成)
- v0.3: 扩充 IRB 5500 / 6700 等更多机型专门 few-shot
- v0.4: 可选 GUI (Textual TUI 或本地 Web)
- v0.5: 完整 RAPID parser, 提升校验深度至语义层
- v0.6: RobotStudio Add-In (C# 桥接), 一键回灌仿真

10.3 方法论可迁移性

本项目沉淀的“**离线 RAG + 领域校验闭环 + 一键交付**”范式不局限于 ABB：更换知识库、提示词与校验规则后，可平移至 KUKA KRL、FANUC TP、安川 INFORM 等其它封闭工业机器人语言，乃至 PLC（结构化文本 ST）等工控代码生成场景，具备清晰的产品化与推广潜力。

11 结论

abb-offline-coder 针对喷涂机器人编程“高门槛 + 无网隔离”的真实困境，提出并完整实现了一套**完全离线、领域专精、生成即校验**的中文 AI 编程助手。通过本地量化大模型与官方手册 RAG 的结合、IRC5/IRC5P 双控制器自适应、11 类静态校验闭环与 Pack&Go 一键交付，系统把“写一段合格喷涂程序”从专家级的数小时工作，降为数十秒的自然语言交互加人工复核，且全程数据不出厂。项目以约 4500 行 Python、149 个测试用例、7497 片段知识库与 20–35 秒端到端性能，证明了“无网工业现场可用的 AI 编程助手”这一路线的技术可行性与工程成熟度，并为更广泛的封闭工业生态代码生成提供了可复制的方法论范式。

参考资料与项目信息

- 项目源码: <https://github.com/Hollis36/abb-offline-coder> (MIT 许可证)
- 在线演示页: <https://hollis36.github.io/abb-offline-coder/>
- ABB *RAPID Reference Manual—Instructions, Functions and Data types*(文档号 3HAC16581)
- ABB *Painting PowerPac Operating Manual* (3HNA019758)、*Application Manual—Robot-Ware Paint*
- ABB *Product Manual*: IRB 52 / 5400 / 5710 系列
- BAAI bge-small-zh-v1.5 中文嵌入模型; Qwen2.5-Coder 开源代码大模型; Ollama 本地推理框架
- ChromaDB 向量数据库; rank-bm25; PyMuPDF; Typer / Rich / Pydantic

项目演示页提供的引用格式 (@software):

```
@software{abb_offline_coder,
  title = {abb-offline-coder: Offline AI assistant for ABB RAPID painting robots},
  author = {Hollis36},
  year = {2026},
  url = {https://github.com/Hollis36/abb-offline-coder},
  note = {Demo: https://hollis36.github.io/abb-offline-coder/, MIT License}
}
```